

Исследование и практическая реализация ЕМ-алгоритма для задачи кластеризации (GMM) Курсовой проект

Студент: Санчук Сергей Александрович
Руководитель: Буславский Александр Андреевич

Белорусский государственный университет
ФПМИ, Кафедра ДМА

Минск, 2025



Введение

Цель работы: Теоретическое исследование EM-алгоритма и разработка программной реализации модели GMM для кластеризации данных сложной структуры.

Основные задачи:

- Провести теоретический анализ модели смеси гауссовых распределений (GMM).
- Вывести формулы EM-алгоритма через вариационную нижнюю границу (ELBO).
- Реализовать алгоритм на Python с поддержкой полной ковариационной матрицы.
- Сравнить эффективность GMM и K-means на синтетических и реальных данных.

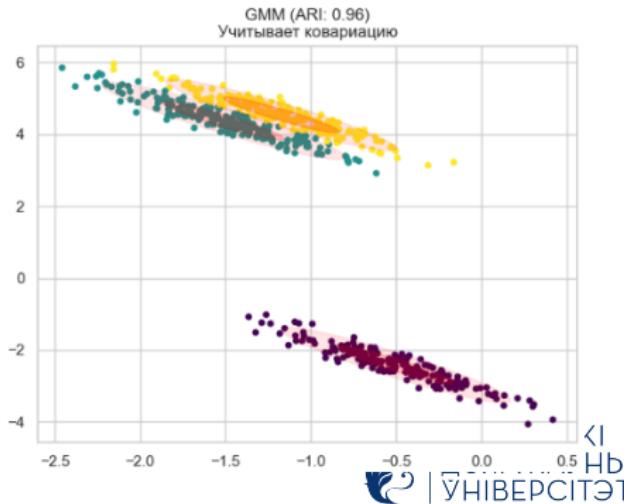


Математическая модель GMM

Плотность вероятности наблюдаемой переменной x :

Формула смеси

$$p(x|\theta) = \sum_{k=1}^K \pi_k \mathcal{N}(x|\mu_k, \Sigma_k)$$



Параметры θ :

- π_k — вес компоненты ($\sum \pi_k = 1$);
- μ_k — центр кластера;
- Σ_k — ковариационная матрица.

Метод максимального правдоподобия (MLE)

Необходимо максимизировать логарифм функции правдоподобия:

$$\ln p(X|\theta) = \sum_{n=1}^N \ln \left(\sum_{k=1}^K \pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k) \right) \rightarrow \max_{\theta}$$

Проблема: Сумма находится под знаком логарифма ($\ln \sum$).

- Аналитическое решение невозможно.
- Необходим итерационный метод (EM-алгоритм).

Вариационная нижняя граница (ELBO)

Для формализации задачи вводятся латентные переменные Z и вариационное распределение $q(Z)$.

Используя декомпозицию правдоподобия и неотрицательность KL -дивергенции ($KL \geq 0$), получаем нижнюю оценку:

$$\ln p(X|\theta) = \mathcal{L}(q, \theta) + KL(q(Z|X)||p(Z|X, \theta)) \geq \mathcal{L}(q, \theta)$$

Раскроем структуру ELBO (как разность Энергии и Энтропии):

Структура ELBO

$$\mathcal{L}(q, \theta) = \underbrace{\mathbb{E}_q[\ln p(X, Z|\theta)]}_{\text{Energy (Ожидаемое правдоподобие)}} - \underbrace{\mathbb{E}_q[\ln q(Z)]}_{\text{Entropy (Энтропия)}}$$

Суть EM-алгоритма: Мы итеративно максимизируем этот функционал, приближая нижнюю границу к истинному правдоподобию.



Общая схема итерации EM

Алгоритм состоит из попеременной оптимизации границы $\mathcal{L}(q, \theta)$:

E-step (Optimization w.r.t. q)

Фиксируем $\theta^{(t)}$. Находим распределение q , максимизирующее ELBO (что эквивалентно минимизации KL-дивергенции):

$$q^{(t+1)} = \arg \max_q \mathcal{L}(q, \theta^{(t)}) = \arg \min_q KL(q||p)$$

Решение: $q^{(t+1)}(Z) = p(Z|X, \theta^{(t)})$ (апостериорное распределение).

M-step (Optimization w.r.t. θ)

Фиксируем $q^{(t+1)}$. Находим параметры θ , максимизирующие Энергию:

$$\theta^{(t+1)} = \arg \max_{\theta} \mathbb{E}_{q^{(t+1)}} [\ln p(X, Z|\theta)]$$

Скрытые переменные в задаче GMM

Что выбрать в качестве скрытых переменных?

- $z_{nk} \in \{0, 1\}$ — индикатор: принадлежит ли объект x_n компоненте k .
 - $\gamma_{nk} = p(z_{nk} = 1 | x_n)$ — вероятность принадлежности.
- ❶ На Е-шаге нужно минимизировать $KL(q(Z|X) || p(Z|X, \theta))$.
 - ❷ Минимум $KL = 0$ достигается, когда $q(Z|X) = p(Z|X, \theta)$.

По формуле Байеса истинное апостериорное распределение:

$$p(z_{nk} = 1 | x_n, \mu_k, \Sigma_k) = \frac{\pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k)}{\sum_j \pi_j \mathcal{N}(x_n | \mu_j, \Sigma_j)} = \gamma_{nk}$$

Вывод: Полагая $q(z_{nk} = 1) = \gamma_{nk}$, мы делаем $KL = 0$ и $ELBO = \ln p(X)$.

М-шаг для смеси гауссиан

Максимизируем ожидаемое правдоподобие:

$$Q(\theta) = \sum_{n=1}^N \sum_{k=1}^K \gamma_{nk} \ln (\pi_k \mathcal{N}(x_n | \mu_k, \Sigma_k)) \rightarrow \max_{\pi, \mu, \Sigma}$$

Результаты оптимизации:

- ① **Веса** π_k : Используя метод множителей Лагранжа (ограничение $\sum \pi_k = 1$), получаем:

$$\pi_k^{new} = \frac{1}{N} \sum_{n=1}^N \gamma_{nk}$$

- ② **Параметры Гауссиан** (μ_k, Σ_k): Приравнивая производные к нулю:

$$\mu_k^{new} = \frac{\sum_n \gamma_{nk} x_n}{\sum_n \gamma_{nk}}, \quad \Sigma_k^{new} = \frac{\sum_n \gamma_{nk} (x_n - \mu_k)(x_n - \mu_k)^T}{\sum_n \gamma_{nk}}$$



Связь с алгоритмом K-means

Рассмотрим GMM с ограничениями: $\Sigma_k = \epsilon I$, $\pi_k = 1/K$.

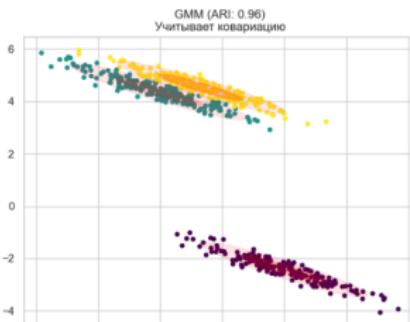
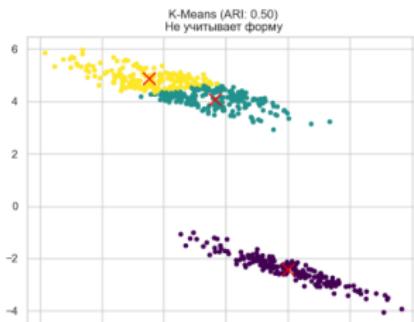
Подставим плотность нормального распределения в формулу γ_{nk} :

$$\gamma_{nk} = \frac{\exp\left(-\frac{1}{2\epsilon}\|x_n - \mu_k\|^2\right)}{\sum_{j=1}^K \exp\left(-\frac{1}{2\epsilon}\|x_n - \mu_j\|^2\right)}$$

Предельный переход $\epsilon \rightarrow 0$: В сумме доминирует слагаемое с минимальным расстоянием $\|x_n - \mu\|^2$.

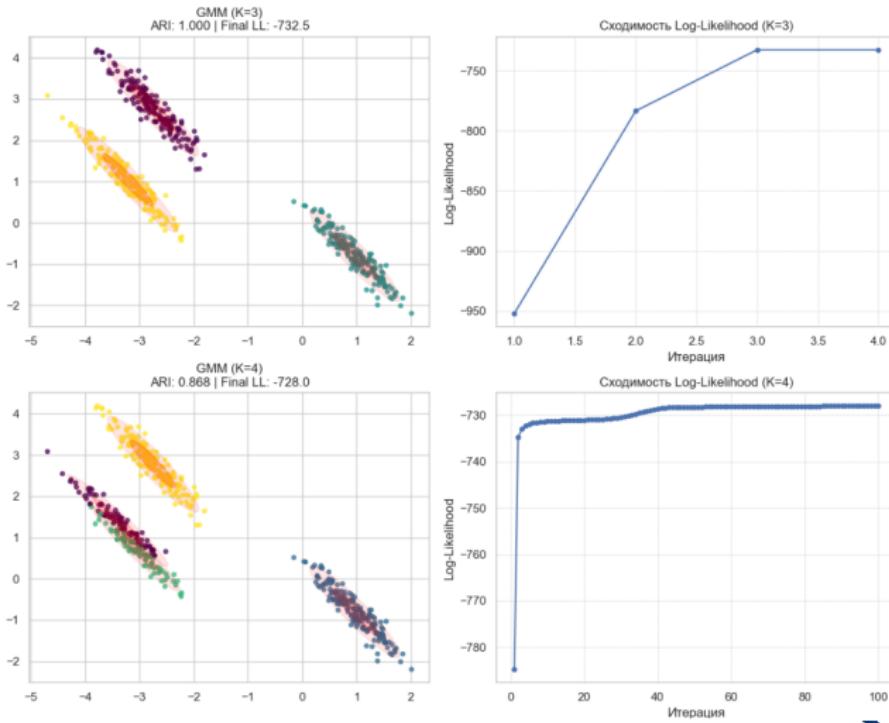
$$\lim_{\epsilon \rightarrow 0} \gamma_{nk} = \begin{cases} 1, & \text{если } k = \arg \min_j \|x_n - \mu_j\|^2 \\ 0, & \text{иначе} \end{cases}$$

Мягкая вероятность становится жесткой меткой (Hard assignment).



Эксперимент 1: Анализ сходимости

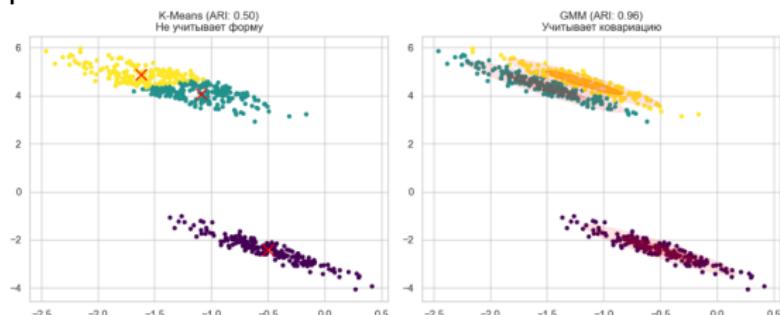
На графике представлена зависимость Log-Likelihood от номера итерации.
Алгоритм монотонно увеличивает правдоподобие.



Эксперимент 2: Анизотропные данные

Сравнение на вытянутых кластерах.

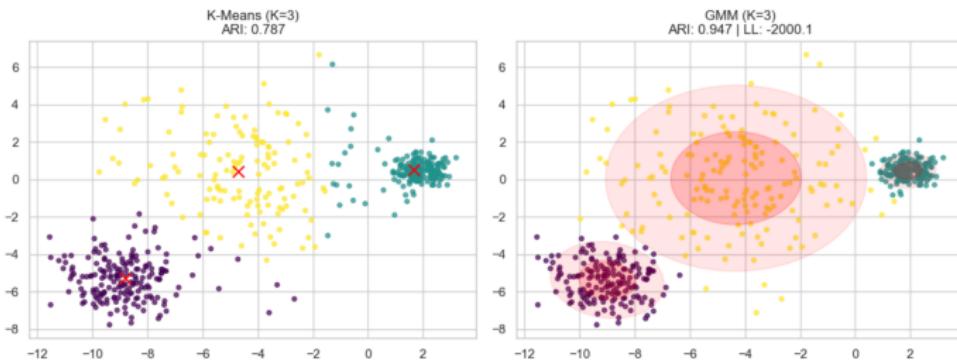
- **K-means:** «Разрезает» кластеры, так как ищет сферы.
- **GMM:** Обучает полную матрицу Σ , подстраиваясь под наклон данных.



Эксперимент 3: Различная дисперсия

Ситуация: плотный кластер рядом с разреженным.

Анализ датасета: Varied Variance (Разная плотность)



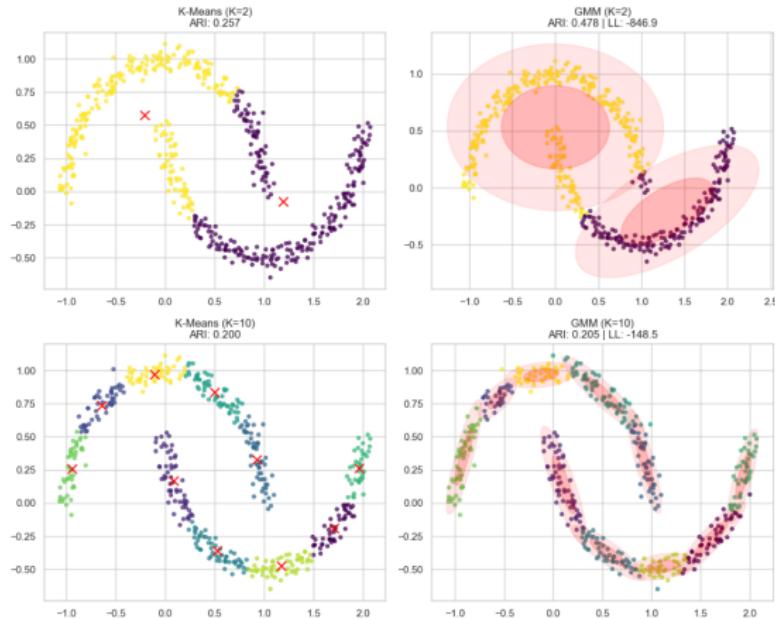
GMM корректно определяет границы, учитывая разный «размер» (дисперсию) кластеров.



Эксперимент 4: Невыпуклые данные

Аппроксимация датасета «Moons» ($K = 10$).

Анализ датасета: Moons (Невыпуклые данные)

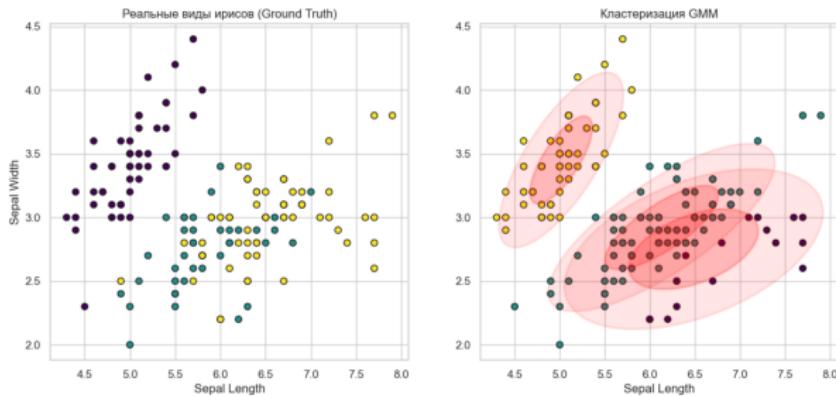


GMM может использоваться как универсальный аппроксиматор произвольной плотности вероятности.



Эксперимент 5: Ирисы Фишера

Визуализация кластеризации реальных данных.



Для пересекающихся классов (*Versicolor* и *Virginica*) алгоритм возвращает мягкие вероятности ($\gamma \approx 0.5$).

Заключение

Результаты работы:

- ❶ Изучен математический аппарат EM-алгоритма.
- ❷ Разработана эффективная реализация на Python (Vectorization, Log-Sum-Exp trick).
- ❸ Экспериментально подтверждено преимущество GMM перед K-means на данных сложной структуры (анизотропия, разная плотность).

Спасибо за внимание!

